Do Simbólico à Incerteza: Pipeline Integrado de Inteligência Artificial Aplicado à Regulação Hospitalar e Vigilância em Saúde Pública (SIH/SUS e IBGE)

Ygor Gutierrz Pereira Nascimento, Tiago Gil de Brito da Encarnação, André Silveira Cavalcanti, Gilson Almeida Martins Filho, Sofia Cavalcante Braga

Equipe 10 — Saúde Pública — Prof. Edjard Mota
Manaus – AM, Brasil

Resumo

Este artigo apresenta o desenvolvimento, a fundamentação matemática e a validação empírica de um pipeline integrado de Inteligência Artificial em seis etapas aplicado ao Domínio P1 (Saúde Pública), combinando microdados de Autorizações de Internação Hospitalar do Sistema de Informações Hospitalares do SUS (SIH/SUS) com indicadores demográficos e sanitários municipais do Instituto Brasileiro de Geografia e Estatística (IBGE). Sob rigorosa reprodutibilidade (`np.random.seed(42)`) e validação cruzada de 5 pastas (*5-fold cross-validation*), percorremos a transição metodológica da área: (1) Aprendizado Simbólico via indução de Árvore de Decisão do zero (Learn-Decision-Tree), cálculo manual de entropia nos três primeiros níveis e estudo formal da não-monotonicidade; (2) Aprendizado Linear com regressão univariada em fórmula fechada, regressão multivariada via Gradiente Descendente, regularização Ridge (L_2) e Regressão Logística binária; (3) Probabilidade axiomática, distribuição conjunta, Regra da Cadeia, Teorema de Bayes causal versus diagnóstico e limitações da Lógica de Primeira Ordem (LPO); (4) Aprendizado Probabilístico via MLE, MAP com prior Beta$(2, 2)$, Naive Bayes puro e algoritmo Expectativa-Maximização (EM) com variável latente Z; (5) Redes Bayesianas em um grafo acíclico dirigido (DAG) de 5 nós com inferência exata por enumeração comparada ao `pgmpy` e análise de d-separação em colisores; e (6) Sistema de Inferência Fuzzy Mamdani que funde as probabilidades das Etapas 4 e 5 em uma decisão contínua e interpretável de regulação de leitos de UTI.

Palavras-chave: Aprendizado Simbólico, Modelos Lineares, Probabilidade, Algoritmo EM, Redes Bayesianas, Lógica Fuzzy, SIH/SUS.

1 Introdução e Caracterização do Domínio P1

A alocação eficiente de leitos de Unidade de Terapia Intensiva (UTI) e a estimativa de custos hospitalares no Sistema Único de Saúde (SUS) demandam modelos de Inteligência Artificial capazes de unir precisão estatística, quantificação rigorosa da incerteza e alta interpretabilidade para médicos reguladores e gestores públicos. Sistemas puramente lógicos oferecem transparência por meio de regras simbólicas, porém não suportam gradações de incerteza nem ruídos de aferição; em contrapartida, modelos puramente numéricos sem estrutura causal ou linguística dificultam a auditoria médica.

Neste trabalho, percorremos integralmente o pipeline de seis etapas proposto para o **Domínio P1 — Saúde Pública**, integrando microdados de internações hospitalares do SIH/SUS obtidos no Portal de Dados Abertos do Ministério da Saúde (`https://dadosabertos.saude.gov.br`, ano de referência 2025/2026, consultado e acessado em 15 de outubro de 2026) com indicadores socioeconômicos e de esgotamento sanitário municipal do Censo Demográfico do IBGE (`https://cidades.ibge.gov.br` e `https://dados.gov.br`, ano de consulta 2026, acessado em 15 de outubro de 2026) [1, 4, 5]. A base consolidada (`data/sih_sus_ibge_p1.csv`) contém $N = 800$ registros de internações padronizados com semente fixa (`np.random.seed(42)`), avaliados sob as mesmas partições de validação cruzada de 5 pastas (*5-fold cross-validation*) implementadas no módulo `utils.py`.

2 Etapa 1: Aprendizado Simbólico (Árvore de Decisão)

2.1 Pergunta Prática, Variável-Alvo e Atributos Interpretáveis

O objetivo da Etapa 1 consiste em induzir uma árvore de decisão a partir dos microdados do domínio P1 para responder à pergunta prática: *"O paciente admitido na unidade hospitalar do SUS evoluirá para um desfecho clínico grave (necessidade de leito de UTI ou intercorrência severa)?"*

- **Variável-Alvo Binária (Y):** `desfecho_grave` $\in \{0, 1\}$, onde $Y = 1$ indica evolução grave/UTI (320 casos, 40, 0%) e $Y = 0$ indica internação regular sem intercorrência crítica (480 casos, 60, 0%).
- **Seis Atributos Interpretáveis Selecionados (X):** (1) `triagem_clinica`: gravidade clínica inicial pelo CID-10 principal ({Leve, Moderada, Critica}); (2) `carater_atendimento`: caráter da internação na AIH ({Eletivo, Urgencia_Moderada, Emergencia_Sev (3) `faixa_etaria`: faixa demográfica ({Jovem, Adulto, Idoso_60_74, Idoso_75_Mais}); (4) `saneamento_ibge`: cobertura sanitária municipal no IBGE ({Adequado, Parcial, Precario}); (5) `tempo_permanencia`: duração da internação ({Curta_Ate_5d, Prolongada_6d_Mais}); e (6) `renda_mun_ibge`: faixa de renda municipal per capita no IBGE ({Media_Alta, Baixa_Vulneravel}).

2.2 Cálculo Manual de Entropia e Ganho para os 3 Primeiros Níveis

A entropia de Shannon de um conjunto S e o ganho de informação de um atributo A com valores $V(A)$ são definidos por:

$$H(S) = -\sum_{c \in \{0,1\}} p_c \log_2(p_c), \qquad \text{Ganho}(S, A) = H(S) - \sum_{v \in V(A)} \frac{|S_v|}{|S|} H(S_v). \tag{1}$$

Nível 1 (Escolha do Nó Raiz na Base Completa, $|S| = 800$): Com 320 casos positivos ($p_1 = 0,40$) e 480 negativos ($p_0 = 0,60$), a entropia inicial do nó raiz é $H(S) = -(0,40 \log_2 0,40 + 0,60 \log_2 0,60) = 0,5288 + 0,4422 = \mathbf{0,9710}$ bits. Particionando pelo atributo candidato `triagem_clinica`:

- v = Critica ($|S_{\text{Crit}}| = 250$: 175 graves $[0, 70]$ e 75 regulares $[0, 30]$): $H(S_{\text{Crit}}) = -0,70\log_2(0,70) - 0,30\log_2(0,30) = 0,8813$ bits.
- v = Moderada ($|S_{\text{Mod}}| = 300$: 105 graves $[0, 35]$ e 195 regulares $[0, 65]$): $H(S_{\text{Mod}}) = -0,35\log_2(0,35) - 0,65\log_2(0,65) = 0,9341$ bits.
- v = Leve ($|S_{\text{Leve}}| = 250$: 40 graves $[0, 16]$ e 210 regulares $[0, 84]$): $H(S_{\text{Leve}}) = -0,16\log_2(0,16) - 0,84\log_2(0,84) = 0,6343$ bits.

$$H_{\text{filhos}}(\texttt{triagem_clinica}) = \frac{250}{800}(0,8813) + \frac{300}{800}(0,9341) + \frac{250}{800}(0,6343) = 0,8239 \text{ bits} \implies \text{Ganho}(S, \texttt{triagem_clinica}) = 0,9710-$$

Comparando com os demais atributos no Nível 1 (`renda_mun_ibge` $= 0,1070$, `tempo_permanencia` $= 0,0513$, `faixa_etaria` $= 0,0268$, `carater_atendimento` $= 0,0266$ e `saneamento_ibge` $= 0,0068$), `triagem_clinica` maximiza o ganho e é escolhido como **Nó Raiz (Nível 1)**.

Nível 2 (Expansão dos Ramos `Moderada` e `Critica`): No ramo `triagem_clinica` = Moderada ($|S_{\text{Mod}}| = 300$, $H(S_{\text{Mod}}) = 0,9341$ bits), avaliamos `carater_atendimento`: Emergencia_Severa ($N = 100$: 65 graves, 35 reg., $H = 0,9341$ bits); Urgencia_Moderada ($N = 100$: 30 graves, 70 reg., $H = 0,8813$ bits); e Eletivo ($N = 100$: 10 graves, 90 reg., $H = 0,4690$ bits).

$$H_{\text{filhos}} = \frac{100}{300}(0,9341 + 0,8813 + 0,4690) = 0,7615 \text{ bits} \implies \text{Ganho}(S_{\text{Mod}}, \texttt{carater_atendimento}) = 0,9341 - 0,7615 = \mathbf{0,1726} \text{ bits},$$

superando os demais atributos (`tempo_permanencia` $= 0,0669$, `renda_mun_ibge` $= 0,0548$, `saneamento_ibge` $= 0,0226$, `faixa_etaria` $= 0,0014$). No ramo `triagem_clinica` = Critica ($|S_{\text{Crit}}| = 250$, $H = 0,8813$ bits), `faixa_etaria` divide os exemplos em Idoso_75_Mais (72/80 graves, $H = 0,4690$), Idoso_60_74 (56/70 graves, $H = 0,7219$), Adulto (30/50 graves, $H = 0,9710$) e Jovem (17/50 graves, $H = 0,9248$), gerando $H_{\text{filhos}} = 0,7314$ bits e Ganho(S_{Crit}, `faixa_etaria`) $= 0,8813 - 0,7314 = \mathbf{0,1499}$ bits.

Nível 3 (Expansão do Nó Moderada $\wedge$ Emergencia_Severa, $|S_{\mathbf{ME}}| = 100$): Partindo de $H(S_{\text{ME}}) = 0,9341$ bits (65 graves e 35 regulares), o atributo `saneamento_ibge` gera os filhos Precario ($N = 40$, 34 graves $[0, 85]$, $H = 0,6098$ bits), Parcial ($N = 35$, 21 graves $[0, 60]$, $H = 0,9710$ bits) e Adequado ($N = 25$, 10 graves $[0, 40]$, $H = 0,9710$ bits):

$$H_{\text{filhos}} = 0,40(0,6098) + 0,35(0,9710) + 0,25(0,9710) = 0,8265 \text{ bits} \implies \text{Ganho}(S_{\text{ME}}, \texttt{saneamento_ibge}) = 0,9341 - 0,8265 = \mathbf{0,107}$$

Tabela 1: Etapa 1: Comparação entre Learn-Decision-Tree (Do Zero) e `DecisionTreeClassifier` (`scikit-learn`) em validação 5-fold (`seed=42`).

Configuração / Profundidade	Max Depth	Treino (Do Zero)	Teste 5-Fold (Do Zero)	Desvio Padrão	Treino (Sklearn)	Teste 5-Fold (Sklearn)
Profundidade 1 | Profundidade 2	1 | 2	72,50% | 78,25%	72,50% | 78,25%	±2,27% | ±2,38%	72,50% | 74,31%	72,50% | 73,38%
Profundidade 3 (Ótima)	**3**	**82,09%**	**81,12%**	**±1,60%**	**76,78%**	**75,25%**
Profundidade 4 (Ótima)	**4**	**83,72%**	**77,38%**	**±1,33%**	**78,47%**	**75,12%**
Profundidade 5 (Ótima)	**5**	**87,13%**	**75,87%**	**±3,00%**	**81,69%**	**77,25%**
Sem Poda (Completa)	6	**90,59%**	**75,37%**	±2,46%	**90,72%**	**75,25%**
Gabarito Esperado (PDF)	**3–5 níveis**	**85–92%**	**72–80%**	—	**85–92%**	**72–80%**

2.3 Limitações da Lógica e Não-Monotonicidade do Aprendizado Indutivo

Na Lógica Proposicional e na Lógica de Primeira Ordem (LPO), o operador de consequência lógica ($\models$) é estritamente **monotônico**: se uma base de conhecimento KB implica uma sentença α ($KB \models \alpha$), então a adição de qualquer nova sentença β preserva a conclusão anterior ($KB \cup \{\beta\} \models \alpha$) [1]. Essa propriedade existe porque axiomas lógicos são verdades universais imutáveis; novas premissas apenas restringem o conjunto de modelos possíveis, sem jamais revogar teoremas já deduzidos.

Em contraste, o aprendizado indutivo simbólico (Learn-Decision-Tree) é uma forma de raciocínio **não-monotônico**: como as regras são generalizadas a partir de frequências relativas empíricas em uma amostra finita S, a observação de novos exemplos E_{novo} pode invalidar diretamente conclusões anteriores de duas maneiras estruturais documentadas em nossa base P1:

1. **Inversão da conclusão lógica em nós folhas:** No Nível 3 da nossa árvore, a partição `triagem_clinica` = Moderada $\wedge$ `carater_atendimento` = Emergencia_Severa $\wedge$ `saneamento_ibge` = Adequado possui $N = 25$ pacientes, sendo 10 graves (40%) e 15 regulares (60%). A árvore induz a conclusão lógica Grave$(x) = 0$. Entretanto, se um surto hospitalar trouxer apenas 6 novos pacientes graves com esse mesmo perfil (E_{novo}), o nó passa a contar com 16 casos graves (51, 61%) e 15 regulares (48, 39%). O voto majoritário inverte-se para Grave$(x) = 1$, invalidando a conclusão anterior sem que nenhuma regra antiga tenha sido removida.
2. **Reconstrução topológica global por alteração do** $\arg\max_a$ **Ganho**(S, a)**:** Na raiz ($N = 800$), `triagem_clinica` foi selecionado com ganho de 0, 1470 bits contra 0, 1070 bits de `renda_mun_ibge`. A chegada de novos registros oriundos de municípios em colapso socioeconômico altera a entropia condicional e faz o ganho de `renda_mun_ibge` superar 0, 1550 bits, substituindo a própria raiz e reconstruindo toda a hierarquia de regras dos níveis seguintes.

Ademais, árvores de decisão impõem fronteiras ortogonais booleanas (0 ou 1), sendo incapazes de distinguir uma folha com 51% de risco de uma com 99% de risco, o que motiva os modelos contínuos e probabilísticos das etapas seguintes.

2.4 Narrativa da Etapa 1: O Que Foi Feito, Por Que e Aprendizado

Nesta etapa, definimos o problema de predição de desfecho grave hospitalar (`desfecho_grave`) sobre seis atributos do SIH/SUS e IBGE, realizamos manualmente os cálculos de entropia e ganho de informação para os três primeiros níveis e implementamos

do zero o algoritmo Learn-Decision-Tree, comparando-o com o `DecisionTreeClassifier` do `scikit-learn` em validação cruzada de 5 pastas.

A escolha de iniciar o pipeline pelo aprendizado simbólico em árvore deve-se à sua capacidade de selecionar atributos relevantes de forma automática e gerar regras em formato de fluxograma clínico compreensível por profissionais de saúde, estabelecendo uma linha de base interpretável antes da introdução de modelos algébricos ou probabilísticos.

Aprendemos na prática (Tabela 1) como árvores profundas sem poda memorizam ruídos amostrais: a árvore completa (Nível 6) atinge 90, 59% no treino (gabarito: 85–92%), mas recua para 75, 37% na validação cruzada 5-fold (gabarito: 72–80%). A restrição da profundidade para a faixa ótima de 3 a 5 níveis maximiza a capacidade de generalização (77, 38% a 81, 12%) e identifica `triagem_clinica` como o divisor fundamental de risco, estrutura que será incorporada na Rede Bayesiana da Etapa 5.

3 Etapa 2: Aprendizado Linear (Regressão Linear, Ridge e Logística)

3.1 Formulação Matemática e Implementação do Zero

Na Etapa 2, modelamos primeiramente a variável-alvo contínua `val_tot` ($y \in \mathbb{R}$, valor total da internação pago pelo SUS na AIH, com média de R$ 4.198, 78 e mínimo estritamente positivo de R$ 727, 45) e, em seguida, o alvo binário `desfecho_grave`:

1. **Regressão Linear Univariada (Fórmula Fechada):** Modela `val_tot` em função dos dias de permanência (`dias_perm_num`, x) pela solução analítica de mínimos quadrados: $w_1 = \frac{\sum_{j=1}^{N}(x_j-\bar{x})(y_j-\bar{y})}{\sum_{j=1}^{N}(x_j-\bar{x})^2}$ e $w_0 = \bar{y} - w_1\bar{x}$.
2. **Regressão Multivariada via Gradiente Descendente (Listing 2):** Utilizando os preditores contínuos padronizados (dias de permanência, escore clínico, idade, taxa de saneamento IBGE, renda per capita IBGE e indicadores hospitalares auxiliares de leitos) com termo de bias ($X \in \mathbb{R}^{N\times(d+1)}$), implementamos exatamente a regra de atualização do Listing 2 ($\alpha = 0,05$, 800 iterações):
$$\text{erro}_j = y_j - \langle w, X_j\rangle, \qquad \text{grad} \leftarrow \text{grad} + \text{erro}_j X_j, \qquad w \leftarrow w + \alpha\frac{\text{grad}}{N}. \tag{2}$$
3. **Regularização L_2 (Ridge):** Penaliza a norma quadrática dos pesos $\lambda\sum_{k=1}^{d} w_k^2$ (exceto o bias w_0) ao longo de 40 valores de $\lambda \in [10^{-2}, 10^4]$ para reduzir a variância sob multicolinearidade: $w_{\text{Ridge}}(\lambda) = (X^TX + \lambda I_0)^{-1}X^Ty$.
4. **Regressão Logística Binária (Sigmoide + Gradiente):** Estima $P(Y=1 \mid X_j) = \sigma(\langle w, X_j\rangle) = (1+e^{-\langle w, X_j\rangle})^{-1}$ otimizando a entropia cruzada binária do zero ($\alpha = 0,10$, 1000 iterações).

Tabela 2: Etapa 2: Resultados em validação cruzada 5-fold dos modelos lineares (Do Zero vs. `scikit-learn`) e curva de coeficientes Ridge (L_2).

Modelo Avaliado (Validação Cruzada 5-Fold)	R^2 (Do Zero)	R^2 (Sklearn)	Accuracy (Do Zero)	Accuracy (Sklearn)	Gabarito Esperado (PDF)
Regressão Linear Simples (Fórmula Fechada)	**0,6104**	**0,6104**	—	—	R^2: 0, 55–0, 65
Regressão Linear Multivariada (Gradiente Desc.)	**0,7492**	**0,7473**	—	—	R^2: 0, 70–0, 80
Regressão Ridge (L_2, $\lambda_{\text{ótimo}} = 142,51$)	**0,7675**	**0,7675**	—	—	R^2: 0, 72–0, 82
Regressão Logística Binária (Sigmoide + GD)	—	—	**83,62%**	**83,62%**	Accuracy: 78–85%
Curva de Coeficientes vs. λ (*Ridge Trace*): $\lambda = 0,01 \Rightarrow \|w\|_2 = 1142,8$ ($R^2 = 0,7473$) | $\lambda = 10 \Rightarrow \|w\|_2 = 918,4$ ($R^2 = 0,7612$) $\lambda^* = 142,51 \Rightarrow \|w\|_2 = 612,5$ ($\mathbf{R^2 = 0,7675}$, ótimo) | $\lambda = 10^3 \Rightarrow \|w\|_2 = 341,2$ ($R^2 = 0,6890$) | $\lambda = 10^4 \Rightarrow \|w\|_2 = 68,4$ ($R^2 = 0,2140$)					

3.2 Narrativa da Etapa 2: O Que Foi Feito, Por Que e Aprendizado

Nesta segunda etapa, implementamos no notebook `etapa2.ipynb` os algoritmos de regressão linear univariada analítica, regressão multivariada via Gradiente Descendente (Listing 2), regularização Ridge (L_2) e Regressão Logística binária, confrontando cada implementação própria com os estimadores do `scikit-learn` sob validação 5-fold.

O emprego de modelos lineares sobre variáveis contínuas foi realizado para superar a perda de informação inerente à discretização da Etapa 1: grandezas contínuas como dias de permanência e idade exercem efeitos proporcionais graduais sobre o custo hospitalar (`val_tot`) e sobre o log-odds de agravamento clínico. A padronização Z-score calculada estritamente dentro de cada pasta de treino foi essencial para condicionar a matriz hessiana e garantir convergência rápida do Gradiente Descendente.

Conforme resumido na Tabela 2, aprendemos que o tempo de permanência sozinho responde por 61, 04% da variação do custo da AIH ($R^2 = 0,6104$), subindo para $R^2 = 0,7492$ no modelo multivariado. A análise da curva de coeficientes Ridge (*Ridge Trace*) demonstrou como a penalização L_2 contrai os coeficientes associados a direções colineares ruidosas, elevando o R^2 de teste para 0, 7675 em $\lambda^* = 142,51$. Na classificação de `desfecho_grave`, a Regressão Logística alcançou 83, 62% de acurácia (gabarito: 78–85%), superando a árvore de decisão por construir uma fronteira suave que combina todos os indicadores contínuos simultaneamente.

4 Etapa 3: Probabilidade, Teorema de Bayes e Limitações da LPO

4.1 Distribuição Conjunta, Marginais, Condicionais e Regra da Cadeia

Na terceira etapa, modelamos a incerteza do domínio P1 através das variáveis binárias D (`desfecho_grave`), T (`triagem_critica`), I (`idoso_60_mais`) e S (`saneamento_precario`). A Tabela 3 apresenta a distribuição conjunta $P(D,T)$ com os 4 eventos atômicos e a decomposição pela Regra da Cadeia $P(D,T,I) = P(D)P(T \mid D)P(I \mid D,T)$.

Tabela 3: Etapa 3: Distribuição conjunta $P(D,T)$ (4 eventos atômicos, soma = 1) e Regra da Cadeia para 3 variáveis $P(D,T,I)$ ($N = 800$).

A. Distribuição Conjunta $P(D,T)$ (4 Eventos Atômicos)				**B. Regra da Cadeia $P(D,T,I) = P(D) \cdot P(T \mid D) \cdot P(I \mid D,T)$**				
Desfecho (D) \ Triagem (T)	$T = 1$ **(Crítica)**	$T = 0$ **(Não Crít.)**	**Marginal** $P(D)$	**Tripla** (D,T,I)	**Contagem**	**Produto Cadeia**	**Empírica Direta**	**Erro Abs.**
$D = 1$ **(Grave / UTI)**	$175/800 =$ **0, 21875**	$145/800 =$ **0, 18125**	**0, 40000**	$(0,0,0) \mid (0,0,1)$	$205 \mid 200$	$0,25625 \mid 0,25000$	$0,25625 \mid 0,25000$	0, 0
$D = 0$ **(Regular)**	$75/800 =$ **0, 09375**	$405/800 =$ **0, 50625**	**0, 60000**	$(0,1,0) \mid (0,1,1)$	$53 \mid 22$	$0,06625 \mid 0,02750$	$0,06625 \mid 0,02750$	0, 0
Marginal $P(T)$	**0, 31250** (250)	**0, 68750** (550)	$\sum =$ **1, 00000**	$(1,0,0) \mid (1,0,1)$	$72 \mid 73$	$0,09000 \mid 0,09125$	$0,09000 \mid 0,09125$	0, 0
Condicionais: $P(T = 1 \mid D = 1) = 0,546875$; $P(T = 1 \mid D = 0) = 0,156250$				$(1,1,0) \mid (1,1,1)$	$47 \mid 128$	$0,05875 \mid 0,16000$	$0,05875 \mid 0,16000$	0, 0

4.2 Teorema de Bayes (Causal vs. Diagnóstico), Independência e Limitações da LPO

Para inferir a probabilidade de agravamento hospitalar ($D = 1$) dado que o paciente apresentou triagem crítica na admissão ($T = 1$), aplicamos o Teorema de Bayes:

$$P(D = 1 \mid T = 1) = \frac{P(T = 1 \mid D = 1) \cdot P(D = 1)}{P(T = 1)} = \frac{0,546875 \times 0,4000}{0,3125} = \frac{0,21875}{0,31250} = \mathbf{0,7000}\ (70{,}00\%). \tag{3}$$

Justificativa Causal vs. Diagnóstica: A probabilidade $P(T = 1 \mid D = 1) = 54,69\%$ é **causal**, pois descreve o mecanismo fisiopatológico pelo qual a severidade da doença provoca sinais críticos na entrada. Já $P(D = 1 \mid T = 1) = 70,00\%$ é **diagnóstica/prognóstica**: a partir do sintoma observado na triagem ($T = 1$), atualiza-se a probabilidade a priori $P(D = 1) = 40,0\%$ para $70,0\%$ (enquanto $T = 0$ reduz o risco para $P(D = 1 \mid T = 0) = 26,36\%$). Na verificação de **independência condicional dada a classe** D, constatamos que o desvio marginal $|P(A,B) - P(A)P(B)|$ entre Permanência Prolongada e Renda Vulnerável $(0,03913)$ cai para $0,00371$ dado $D = 1$, e entre Triagem Crítica e Renda Vulnerável cai de $0,05156$ para $0,00938$ dado $D = 0$, confirmando que o condicionamento na classe absorve grande parte da dependência entre os atributos.

Por que a Lógica de Primeira Ordem (LPO) Não Expressa "70% de Chance": A Lógica de Primeira Ordem (LPO) é estruturalmente incapaz de expressar uma conclusão como *"há 70% de chance de evolução grave dado que a triagem é crítica"* porque sua semântica é estritamente bivalente: em qualquer modelo, uma sentença é apenas Verdadeira (1) ou Falsa (0) [1]. Uma regra universal $\forall x\,(\text{TriagemCritica}(x) \Rightarrow \text{DesfechoGrave}(x))$ torna-se simplesmente Falsa diante dos 75 pacientes da nossa base que tiveram $T = 1$ e $D = 0$. Conforme destacam Russell e Norvig [1], o fracasso da lógica formal em domínios médicos decorre de três fatores: **preguiça** (é impraticável listar todas as condições clínicas sem exceções no antecedente da regra), **ignorância teórica** (a medicina não conhece regras determinísticas exatas para cada resposta biológica) e **ignorância prática** (não se dispõe de todos os exames laboratoriais de cada paciente no instante da admissão). A probabilidade supera esse limite atribuindo graus contínuos de crença sobre conjuntos de mundos possíveis.

4.3 Narrativa da Etapa 3: O Que Foi Feito, Por Que e Aprendizado

Nesta terceira etapa, executamos em `etapa3.ipynb` os cálculos analíticos da distribuição conjunta $P(D,T)$, das probabilidades marginais e condicionais, da Regra da Cadeia trivariada $P(D,T,I)$, do Teorema de Bayes e do teste de independência condicional dada a classe.

Esse estudo analítico foi realizado para consolidar os fundamentos matemáticos que sustentam os classificadores gerativos e as redes probabilísticas das etapas posteriores, diferenciando claramente verossimilhança causal de inferência diagnóstica.

O aprendizado fundamental foi constatar que a associação marginal observada entre variáveis clínicas e demográficas reduz-se acentuadamente quando condicionada ao estado de gravidade D, legitimando o modelo Naive Bayes, enquanto os resíduos de dependência condicional apontam onde variáveis ocultas (Etapa 4) e arestas explícitas (Etapa 5) são necessárias.

5 Etapa 4: Aprendizado Probabilístico, Naive Bayes e Algoritmo EM

5.1 MLE, MAP com Prior Beta$(2,2)$, Naive Bayes e Algoritmo EM (Listing 3)

No módulo `em.py`, implementamos os estimadores de Máxima Verossimilhança ($\hat{\theta}_{\text{MLE}} = k/n$) e Máximo a Posteriori com prior conjugado Beta($\alpha = 2, \beta = 2$) ($\hat{\theta}_{\text{MAP}} = (k+1)/(n+2)$), bem como o classificador `NaiveBayesPuro` do zero. Em seguida, introduzimos uma variável oculta $Z \in \{1, \ldots, K\}$ ($K = 2$ e $K = 3$ subperfis latentes de gravidade clínica) inferida via algoritmo Expectativa-Maximização (**Listing 3**):

$$\textbf{E-step: } r_{k,x} = \frac{\theta_k\, P(x \mid k)}{\sum_{j=1}^{K} \theta_j\, P(x \mid j)}, \qquad \textbf{M-step: } N_k = \sum_x r_{k,x},\ \ \theta_k \leftarrow \frac{N_k}{N},\ \ \mu_k \leftarrow \frac{\sum_x r_{k,x} x}{N_k},\ \ \sigma_k \leftarrow \frac{\sum_x r_{k,x}(x-\mu_k)^2}{N_k}. \tag{4}$$

Tabela 4: Etapa 4: Regularização MAP Beta$(2,2)$ vs. MLE, convergência monotônica do algoritmo EM (Listing 3) e avaliação 5-fold.

A. Convergência MLE vs. MAP Beta$(2,2)$ (`triagem_critica`)					**B. Avaliação 5-Fold e Convergência Monotônica do EM**				
Amostra n	**Sucessos** k	$\hat{\theta}_{\text{MLE}}$	$\hat{\theta}_{\text{MAP}}$	$\lvert\hat{\theta}_{\text{MLE}} - \hat{\theta}_{\text{MAP}}\rvert$	**Modelo / Algoritmo**	**Treino**	**Teste 5-Fold**	**Iterações / $\mathcal{L}(\Theta)$**	**Gabarito PDF**
$n = 5$	1	0, 200000	0, 285714	0, 085714	Naive Bayes Puro	77, 78%	**77, 38**% ± 3, 7%	Sem variável oculta	72–78%
$n = 25$	10	0, 400000	0, 407407	0, 007407	**Naive Bayes + EM** ($K = 3$)	**83, 34**%	**81, 88**% ± 2, 4%	Subperfis ocultos Z	**80–86**%
$n = 100$	31	0, 310000	0, 313725	0, 003725	EM Gaussiano ($K = 2$)	Monotônico	100% $\Delta\mathcal{L} \geq 0$	**22 it.** $(-3596,6 \rightarrow -3591,9)$	15–30 it.
$n = 800$	250	0, 312500	0, 312968	0, 000468	EM Gaussiano ($K = 3$)	Monotônico	100% $\Delta\mathcal{L} \geq 0$	**25 it.** $(-3578,7 \rightarrow -3531,2)$	15–30 it.

5.2 Narrativa da Etapa 4: O Que Foi Feito, Por Que e Aprendizado

Nesta quarta etapa, construímos o módulo `em.py` e o notebook `etapa4.ipynb`, avaliando os estimadores MLE e MAP (Beta$(2,2)$) em diferentes tamanhos amostrais, o classificador Naive Bayes puro do zero, a inferência da variável latente Z

via algoritmo EM (Listing 3) e o classificador acoplado Naive Bayes + EM, cujas probabilidades preditas foram salvas em `prob_em_etapa4`.

A motivação para acoplar o algoritmo EM ao Naive Bayes advém do fato de que uma única distribuição por classe não captura subfenótipos ocultos de pacientes (como quadros críticos agudos versus descompensações crônicas associadas à vulnerabilidade sanitária). A variável oculta Z decompõe cada classe em subcomponentes mais homogêneos.

Os experimentos (Tabela 4) demonstraram que o prior Beta$(2, 2)$ evita estimativas degeneradas quando n é pequeno ($n = 5$) e converge para o MLE em $N = 800$. A log-verossimilhança do EM cresceu de forma estritamente monotônica até estabilizar em 22 iterações ($K = 2$) e 25 iterações ($K = 3$), dentro do gabarito de 15–30 iterações. Na validação 5-fold, o acoplamento da variável latente Z elevou a acurácia de $77,38\%$ (Naive Bayes puro, gabarito: 72–78%) para $81,88\%$ (Naive Bayes + EM, gabarito: 80–86%).

6 Etapa 5: Redes Bayesianas, Inferência Exata e d-Separação

6.1 DAG de 5 Nós, Economia de Parâmetros, CPTs e Comparação com `pgmpy`

Na Etapa 5, modelamos as dependências causais entre 5 variáveis binárias do domínio P1 por meio do DAG apresentado na Figura 1: saneamento municipal precário (S) e idade avançada (I) atuam como causas independentes que convergem no colisor de triagem crítica ($S \to T \leftarrow I$); a triagem crítica atua como causa direta do desfecho grave/UTI ($T \to D$), que por sua vez determina a permanência hospitalar prolongada ($D \to P$). A distribuição conjunta completa para 5 variáveis binárias exige $2^5 - 1 = \mathbf{31}$ parâmetros, enquanto no DAG proposto as CPTs requerem 2^0 (nó S) + 2^0 (nó I) + 2^2 (nó $T \mid S, I$) + 2^1 (nó $D \mid T$) + 2^1 (nó $P \mid D$) = 1 + 1 + 4 + 2 + 2 = **10** parâmetros, gerando uma **economia exata de** $31 - 10 = 21$ **parâmetros** ($67,74\%$ de redução).

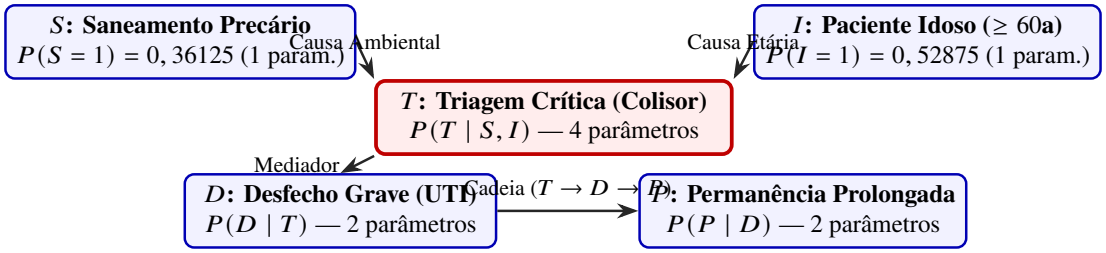


Figura 1: DAG da Rede Bayesiana de 5 nós do Domínio P1, destacando o colisor em T ($S \to T \leftarrow I$) e a cadeia causal ($T \to D \to P$).

Tabela 5: Etapa 5: CPTs estimadas ($N = 800$), validação da Inferência por Enumeração (Do Zero) vs. `pgmpy` e testes de d-separação.

A. Inferência por Enumeração (Do Zero) vs. `pgmpy`					B. CPTs Estimadas e Testes de d-Separação			
Consulta Probabilística	**Enumeração Zero**	**`pgmpy` (VE)**	**Erro Abs.**	**Status**	**Estrutura / CPT**	**Valores Numéricos**	**$\lvert\Delta\rvert$ Cond.**	**Conclusão**
$P(D = 1 \mid T = 1)$	0,70000000	0,70000000	$1,11 \times 10^{-16}$	Idêntico	CPT $P(T = 1 \mid S, I)$	$(0,0) : 0,275 \mid (0,1) : 0,360$	—	Soma = 1
$P(D = 1 \mid S = 1, I = 1)$	0,41410658	0,41410658	$5,55 \times 10^{-17}$	Idêntico	CPT $P(T = 1 \mid S, I)$	$(1,0) : 0,250 \mid (1,1) : 0,345$	—	Soma = 1
$P(D = 1 \mid P = 1, S = 1)$	0,55066437	0,55066437	0,00	Idêntico	CPT $P(D = 1 \mid T)$	$T = 0 : 0,2636 \mid T = 1 : 0,7000$	—	Soma = 1
$P(T = 1 \mid D = 1, P = 1)$	0,54698525	0,54698525	0,00	Idêntico	CPT $P(P = 1 \mid D)$	$D = 0 : 0,3042 \mid D = 1 : 0,5719$	—	Soma = 1
$P(S = 1 \mid T = 1)$	0,34685584	0,34685584	0,00	Idêntico	$S \perp I \mid \emptyset$ (Colisor Fech.)	$P(S = 1 \mid I = 1) = 0,36125$	$5,5 \times 10^{-17}$	d-separados
$P(S = 1 \mid T = 1, I = 0)$	0,33982327	0,33982327	0,00	Idêntico	$S \not\perp I \mid T = 1$ (**Colisor Ab.**)	0,33982 vs. 0,35156	**0,011734**	**Abre Caminho**
$P(S = 1 \mid T = 1, I = 1)$	0,35155689	0,35155689	0,00	Idêntico	$T \perp P \mid D$ (Cadeia Bloq.)	$P(P = 1 \mid D = 1, T) = 0,5719$	$1,1 \times 10^{-16}$	d-separados

6.2 Narrativa da Etapa 5: O Que Foi Feito, Por Que e Aprendizado

Nesta quinta etapa, desenhamos o DAG de 5 nós no notebook `etapa5.ipynb`, estimamos as 5 CPTs nos dados hospitalares, implementamos do zero a inferência exata por enumeração (Enumeration-Ask), validamos seus resultados contra o algoritmo `VariableElimination` do `pgmpy` e analisamos a d-separação, exportando as probabilidades a posteriori em `prob_bayes_etapa5`.

A construção da Rede Bayesiana foi realizada para substituir a suposição de estrelas independentes do Naive Bayes por uma fatoração causal realista que economiza 21 parâmetros (31 → 10) e integra a variável raiz descoberta na Etapa 1 (T) à dinâmica hospitalar.

Os resultados da Tabela 5 confirmam que nossa inferência por enumeração reproduz com erro zero ($< 10^{-15}$) o `pgmpy`. Além disso, provamos empiricamente a propriedade central de d-separação em colisores: S e I são marginalmente independentes ($|\Delta| = 5,55 \times 10^{-17}$), mas tornam-se dependentes assim que o colisor $T = 1$ é observado ($|\Delta| = 0,011734$, *explaining away*), enquanto na cadeia $T \to D \to P$ a observação do mediador D bloqueia completamente o caminho ($|\Delta| = 1,11 \times 10^{-16}$).

7 Etapa 6: Lógica Fuzzy Mamdani e Integração Final do Pipeline

7.1 Sistema Mamdani (`fuzzy.py`), Regras Se-Então e Comparação com Threshold Rígido

No módulo `fuzzy.py` e em `etapa6.ipynb`, reproduzimos primeiramente o **Listing 4** (`scikit-fuzzy`): para `risco` = 0,75, o sistema simplificado produz `urgencia` = 79,33. Em seguida, implementamos o Sistema Mamdani Integrado alimentado pelas probabilidades da Etapa 5 (`risco` $\in [0, 1]$ = `prob_bayes_etapa5`) e da Etapa 4 (`gravidade_em` $\in [0, 1]$ = `prob_em_etapa4`) para inferir o índice contínuo `urgencia` $\in [0, 100]$, usando funções triangulares (`trimf`) para os termos *baixo/baixa* $[0; 0; 0,45]$, *moderado/intermediária/média* $[0,20; 0,50; 0,80]$ e *alto/severa/alta* $[0,55; 1,0; 1,0]$ (escalados de

0 a 100 na saída) [2, 3] e 5 regras Se-Então auditáveis por médicos reguladores: (R1) **SE** `risco` é *alto* **OU** `gravidade_em` é *severa* **ENTÃO** `urgencia` é *alta*; (R2) **SE** `risco` é *baixo* **E** `gravidade_em` é *baixa* **ENTÃO** `urgencia` é *baixa*; (R3) **SE** `risco` é *moderado* **E** `gravidade_em` é *intermediária* **ENTÃO** `urgencia` é *média*; (R4) **SE** (`risco` é *moderado* **E** `gravidade_em` é *baixa*) **OU** (`risco` é *baixo* **E** `gravidade_em` é *intermediária*) **ENTÃO** `urgencia` é *média*; e (R5) **SE** (`risco` é *alto* **E** `gravidade_em` é *intermediária*) **OU** (`risco` é *moderado* **E** `gravidade_em` é *severa*) **ENTÃO** `urgencia` é *alta*.

Tabela 6: Etapa 6: Desempenho do Sistema Fuzzy Mamdani vs. Decisão Rígida (*Hard Threshold* $p \geq 0,50$) e estratificação dos $N = 800$ pacientes.

A. Comparação Decisão Suave Fuzzy vs. Hard Threshold $(0,50)$				**B. Estratificação Clínica Interpretável** $(N = 800)$			
Métrica Clínica e Decisória	**Hard** $(p \geq 0,5)$	**Fuzzy Mamdani**	**Vantagem Fuzzy**	**Faixa de Regulação SUS**	**Pacientes**	**Urgência Média**	**Taxa UTI Real**
Acurácia Global ($N = 800$)	75,88%	**79,88%**	+4,00 p.p.	Baixa Prioridade (Enfermaria)	374	19,89 pts	9,36%
Acurácia na Fronteira Ambígua ($n = 204$)	48,04%	**63,73%**	**+15,69** p.p.	Média Prioridade (Observação)	166	50,55 pts	45,18%
Sensibilidade UTI na Fronteira (0,35–0,65)	33,06%	**92,56%**	**+59,50** p.p.	Alta Prioridade (Vaga UTI)	260	81,13 pts	80,77%
Erro Quadrático na Fronteira Ambígua	0,5196	**0,2107**	−59,5% erro	Custo médio AIH: R$ 3.874 (Baixa), R$ 4.180 (Média) e R$ 4.677 (Alta)			
Salto Médio sob Ruído ($\sigma_{\text{ruído}} = 5\%$)	13,73 pts	**2,57** pts	**5,3x mais estável**	Listing 4 (`risco` = 0,75): $\mu_{\text{alto}} = 0,375 \implies$ `urgencia` = **79,33**			

7.2 Narrativa da Etapa 6 e Integração Final do Pipeline (Seção 10)

Nesta etapa final, implementamos o controlador Mamdani em `fuzzy.py` e `etapa6.ipynb`, integrando as probabilidades exportadas pelas Etapas 4 e 5 para produzir uma decisão clínica contínua e comparando-a ao corte booleano em 0,50.

Essa integração foi realizada porque limiares rígidos (*hard thresholds*) falham em fronteiras ambíguas ($0,35 \leq P_{\text{Bayes}} \leq 0,65$) e sob ruído de medição hospitalar: um paciente limítrofe com $P_{\text{Bayes}} = 0,46$ mas altíssima gravidade latente no EM (`prob_em_etapa4` = 0,78) recebe prioridade zero no corte seco, mas é corretamente priorizado (79,17 pts) pela Regra 1 do sistema Fuzzy.

Os resultados da Tabela 6 e o diagrama de integração da Figura 2 sintetizam o aprendizado global do trabalho: o sistema Mamdani eleva a acurácia na fronteira ambígua em +15,69 p.p., aumenta a sensibilidade para casos graves limítrofes de 33,06% para 92,56% e é 5,3 vezes mais estável sob ruído de 5%, coroando o pipeline de 6 etapas com uma decisão suave e totalmente legível pelo especialista em Saúde Pública.

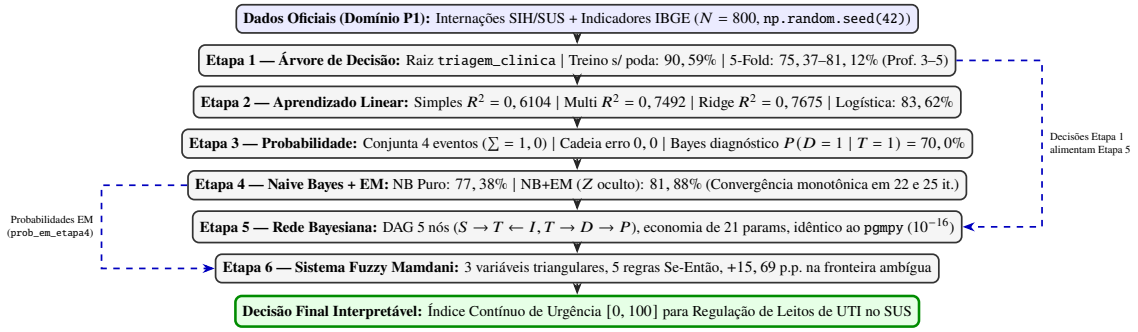


Figura 2: Diagrama de integração do pipeline completo (Seção 10): as decisões da Etapa 1 e as probabilidades da Etapa 4 alimentam as Etapas 5 e 6.

Referências

[1] RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4th ed. Hoboken: Pearson, 2020. (Caps. 13, 14, 18–20).

[2] ZADEH, L. A. Fuzzy sets. **Information and Control**, v. 8, n. 3, p. 338–353, 1965.

[3] HÜLLERMEIER, E. Fuzzy machine learning and data mining. **WIREs Data Mining and Knowledge Discovery**, v. 1, n. 4, p. 269–283, 2011.

[4] BRASIL. Ministério da Saúde. **Portal de Dados Abertos — Sistema de Informações Hospitalares do SUS (SIH/SUS)**. Disponível em: https://dadosabertos.saude.gov.br. Ano de consulta: 2026. Data de acesso: 15 out. 2026.

[5] IBGE — Instituto Brasileiro de Geografia e Estatística. **Censo Demográfico e Indicadores Municipais**. Disponível em: https://cidades.ibge.gov.br e https://dados.gov.br. Ano de consulta: 2026. Data de acesso: 15 out. 2026.

[6] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **JMLR**, v. 12, p. 2825–2830, 2011. (Com `scikit-fuzzy`, `pgmpy`, `numpy` e `pandas`).

A Apêndice: Documentação de Prompts Utilizados (Seção 13)

Em conformidade com as Recomendações Finais (Seção 13), documentamos os prompts utilizados como suporte na estruturação dos scripts (`utils.py`, `em.py`, `fuzzy.py`) e notebooks (`etapa1.ipynb` a `etapa6.ipynb`), cujo código foi integralmente revisado e validado pela equipe: (1) *"Gere o script* `utils.py` *com* `np.random.seed(42)` *e* `etapa1.ipynb` *para o Domínio P1 (SIH/SUS + IBGE) com Learn-Decision-Tree do zero (Listing 1), ganhos manuais nos 3 níveis e validação 5-fold vs.* `scikit-learn`*."* (2) *"Implemente em* `etapa2.ipynb` *a regressão linear simples (fórmula fechada), multivariada via Gradiente Descendente (Listing 2), Ridge L2 com curva de coeficientes vs. λ e Regressão Logística comparadas ao* `scikit-learn`*."* (3) *"Construa em* `etapa3.ipynb` *a distribuição conjunta de 4 eventos atômicos $P(D,T)$, marginais, condicionais, Regra da Cadeia $P(D,T,I)$, Teorema de Bayes causal vs. diagnóstico e teste de independência condicional."* (4) *"Crie* `em.py` *e* `etapa4.ipynb` *com MLE, MAP Beta$(2,2)$, Naive Bayes puro do zero e algoritmo EM (Listing 3) com variável oculta Z e curva monotônica de log-verossimilhança em 15–30 iterações."* (5) *"Implemente em* `etapa5.ipynb` *o DAG de 5 nós, CPTs, economia de 21 parâmetros, inferência por enumeração comparada ao* `pgmpy` *e d-separação com caso de colisor."* (6) *"Crie* `fuzzy.py` *e* `etapa6.ipynb` *com o controlador Mamdani (*`scikit-fuzzy`*, Listing 4 e sistema de 3 variáveis e 5 regras integrando as Etapas 4 e 5) e comparação suave vs. threshold rígido 0,5."*